

1. 개념 계층 & 딥러닝

AI $\supset$ ML $\supset$ DL (포함 관계)

- **AI**: 인간 지능을 모방하는 모든 기법(가장 넓은)
- **ML**: 명시적 프로그래밍 없이 데이터로 패턴 학습
- **DL**: 인공신경망(ANN)으로 패턴 학습

"deep" = 여러 층(layer)을 쌓은 **깊은 신경망**으로 표현(representation) 학습. 신경망은 **퍼셉트론**(인공 뉴런)으로 구성.

2. 퍼셉트론 (Perceptron)

여러 입력 $\rightarrow$ 단일 출력 (생물 뉴런 모방)

$$\hat{y} = f(\sum_i w_i x_i + b)$$

- 입력 $x_{1..m}$, 출력 $\hat{y}$
- 학습 파라미터(learnable) = 가중치 w , 편향 b
- f = 활성화함수(activation)

생물 대응: 수상돌기 $\rightarrow$ 입력, 시냅스 $\rightarrow$ 가중치, 세포체 $\rightarrow$ 합(Σ), 축삭 $\rightarrow$ 출력

3. 활성화함수 (Activation)

목적 = **비선형성(non-linearity)** 부여 $\rightarrow$ 비선형 결정경계 모델링, 임의의 복잡한 함수 근사 가능.

비선형 없으면 층을 쌓아도 단일 선형연산과 동일:

$$a(cx+d)+b = acx+ad+b = Ax+B$$

함수	식	미분 f'	가능
Step	$1(x \geq 0), 0(x < 0)$	$0(x \neq 0)$	✗
Sigmoid	$1/(1+e^{-x})$	$f(1-f)$	✓
Tanh	$(e^x - e^{-x}) / (e^x + e^{-x})$	$1-f^2$	✓
ReLU	$\max(0, x)$	$1(x > 0), 0(x \leq 0)$	✓

Step 불가 이유: gradient가 거의 모든 곳에서 0 $\rightarrow$ 학습 불가. **Tanh** 범위 $-1 \sim 1$.

4. 선형분리 & 논리게이트

선형분리 가능? AND ✓, OR ✓, **XOR ✗**

AND ($w=1, 1$ / $b=-1.5$):

$$x_1 + x_2 - 1.5 = 0$$

OR ($w=1, 1$ / $b=-0.5$):

$$x_1 + x_2 - 0.5 = 0$$

XOR: 단일 퍼셉트론 불가 $\rightarrow$ **MLP(다층퍼셉트론)** 필요.

XOR MLP 해(ReLU): 은닉 w 모두 1, $b_1=0$ · $b_2=-1$; 출력 $w_{31}=1$, $w_{32}=-2$, $b_3=0$

5. 학습 원리 & Loss

학습목표: 예측 $\hat{y}$ 를 정답 y 에 가깝게 $\rightarrow$ **Loss 최소화**

Loss는 task에 따라 선택

- 회귀(연속값): **MSE**, MAE
- 분류(클래스 확률분포 예: [0.1, 0.8, 0.1]): **Cross-Entropy** (binary CE는 특수 경우)

Feed Forward / Back Prop

- **Feed Forward**: 입력 $\rightarrow$ 층 통과 $\rightarrow$ 출력 생성
- **Back Propagation**: 출력층 오차를 역방향 전파해 gradient 계산 $\rightarrow$ 가중치 갱신

Input $\rightarrow$ Hidden $\rightarrow$ Output $\rightarrow$ Error $\rightarrow$ Hidden

6. 경사하강법 (Gradient Descent)

$$W := W - \alpha \cdot \partial J(W) / \partial W$$

α = 학습률(learning rate). gradient 반대 방향으로 반복 이동해 loss 최소화.

방식	업데이트 단위	특징
GD	전체 데이터	정확 / 계산 비쌈
SGD	데이터 1개	빠름 / 매우 noisy
Mini-batch	B개 배치	효율 + 참gradient 근사 $\uparrow$

Mini-batch grad:

$$\partial J / \partial W = (1/B) \sum_{k=1}^B \partial J_k / \partial W$$

알고리즘: ① 가중치 랜덤 초기화 ② 수렴까지 [grad 계산 $\rightarrow$ 갱신] ③ 반환

7. 역전파 예제 (Chain Rule) ★

구조: $x \rightarrow \{W_1, \sigma\} \rightarrow z \rightarrow \{W_2\} \rightarrow \hat{y} \rightarrow J$

$$z = \sigma(W_1 x), \quad \hat{y} = W_2 \sigma(W_1 x), \quad J = (\hat{y} - y)^2$$

$\partial J / \partial W_2$

$$= (\partial J / \partial \hat{y})(\partial \hat{y} / \partial W_2) = 2(\hat{y} - y) \cdot z$$

$\partial J / \partial W_1$

$$\begin{aligned} &= (\partial J / \partial \hat{y})(\partial \hat{y} / \partial z)(\partial z / \partial W_1) \\ &= 2(\hat{y} - y) \cdot W_2 \cdot z(1 - z) \cdot x \end{aligned}$$

Sigmoid 미분 (암기):

$$\sigma'(x) = \sigma(x)(1 - \sigma(x))$$

8. 문제 ① 과적합 (Overfitting)

학습데이터 오차 $\downarrow$ but 테스트데이터 오차 $\uparrow$. (Underfit / **Optimal** / Overfit)

해결책

- **Data Augmentation**: 회전·반전·밝기·노이즈·grayscale·crop 등 변형으로 데이터 인위적 확장
- **Dropout**: 학습 중 은닉노드 일부를 확률 p 로 랜덤 제거. 테스트시 전체 활성화, 출력 $\times (1-p)$ 스케일링
- **Regularization**: loss에 패널티 추가
L1: Cost = $\Sigma(y - \Sigma x \cdot W)^2 + \lambda \Sigma |W_i|$
L2: Cost = $\Sigma(y - \Sigma x \cdot W)^2 + \lambda \Sigma W_i^2$

9. 문제 ② 기울기 소실 (Vanishing Gradient)

역전파 시 입력에 가까울수록 **gradient가 0에 수렴**(소실) $\rightarrow$ 앞쪽 층가 중치 학습이 어려움. (sigmoid 미분 최대 0.25 $\rightarrow$ 곱할수록 작아짐)

해결책

- **ReLU**: 양수 영역에서 미분=1 $\rightarrow$ sigmoid의 vanishing gradient 완화
- **Skip Connection**: 한 개 이상의 층을 우회, gradient가 역으로 흐름 직접 경로 생성

$$\text{출력} = F(x) + x \quad (\text{identity})$$

(예: ResNet 잔차블록, DenseNet)

★ 빠른 암기

- $\sigma' = \sigma(1 - \sigma)$, $\tanh' = 1 - \tanh^2$
- Step ✗ (grad 0), Sigmoid/Tanh/ReLU ✓
- XOR = 단일 퍼셉트론 ✗ $\rightarrow$ MLP ✓
- 회귀=MSE/MAE · 분류=Cross-Entropy
- $W := W - \alpha \cdot \partial J / \partial W$
- Dropout 테스트: 전체 활성화 $\times (1-p)$
- L1=|W| · L2=W²
- Vanishing $\rightarrow$ ReLU + Skip Connection