

L17. ML 흐름 · 일반화

ML Lifecycle 4단계: ①Learning Problem(Target/Objective/Data) → ②Model Design(Model family/Hypothesis space) → ③Optimization(반복 알고리즘/하이퍼파라미터 튜닝) → ④Predict&Evaluate(추론/평가지표)

학습 근사: 참 함수 $f^*: X \rightarrow Y$ 존재, 유한-노이즈 데이터로 f 근사. **목표=일반화**(unseen data 성능)

Generalization: Train 성능 $\neq$ 실제 성능. 같은 분포의 본적 없는 데이터 성능이 중요

L17. 데이터 분할 · 검증

- **Train-Test:** 서플 후 분리 (Train ~85% / Test ~15%). test를 반복해서 엿보면(peek) 정보 누출 → 점수가 일반화 반영 못함
- **Train-Val-Test (70/15/15):** Train=파라미터 학습, **Val=모델/하이퍼파라미터 튜닝**, Test=최종 성능만 보고
- 비유: Train=연습문제, Val=모의고사, Test=실제시험
- **K-Fold CV:** 데이터 적을 때. K개 fold로 나눠 K번 학습 (매번 K-1개 train/1개 val), 검증 점수 평균 → 데이터 최대 활용·견고한 추정

L17. 과소·과대적합

- **Underfit:** 모델 단순 → 패턴 못 잡음 (high bias)
 - **Overfit:** 모델 복잡 → 노이즈 암기, 새 데이터 실패 (high variance)
- Error Curve:** 복잡도 ↑ → **Train error** 단조 감소, **Test error** 감소 후 증가. test 최소점 = 최적 복잡도

L17. 편향-분산 ★

Expected Test Error = Bias² + Variance + Noise

- **Bias:** 모델쪽의 잘못된 가정(체계적 오차). High bias → underfit
 - **Variance:** 학습셋 변화에 대한 민감도. High variance → overfit
 - **Noise:** 데이터 내재 무작위성(축소 불가, irreducible)
- Tradeoff:** 단순 모델=고Bias/저Var, 복잡 모델=저Bias/고Var → 그 사이 sweet spot

L17. 정규화 (Weight Decay) ★

- $L(W) = (1/N) \cdot \sum L_i(f(x_i, W), y_i) + \lambda \cdot R(W)$
- 좌항=Data loss(예측이 데이터와 일치), 우항=불필요한 복잡도에 페널티(과적합 방지)
 - **λ (계수):** ↑일수록 W를 더 강하게 규제(작은 값). $\lambda=0 \rightarrow$ 비정규화와 동일
 - **L2 (Ridge):** $R(W)=\sum W_i^2$ — 가중치를 전반적으로 작게
 - **L1 (Lasso):** $R(W)=\sum |W_i|$ — **희소(sparse) 유도**, 일부 $W=0$ (다이아몬드 꼭짓점에서 최적)

L18. 모수 vs 비모수

- **Parametric:** 고정된 파라미터 수 θ (선형/로지스틱 회귀)
- **Non-parametric:** 복잡도가 데이터와 함께 증가 (k-NN, 결정트리) — 데이터 분포에 강한 가정 X

L18. k-NN ★

- **학습=저장만** (명시적 train phase 없음, 데이터 암기)
 - **예측:** 모든 점과 거리 계산 → k개 최근접 $N_k(x^*) \rightarrow$ **분류=다수결(mode), 회귀=평균(mean)**
 - **결정경계:** 비선형·국소적, 명시적 수식 없음(점 위치로 암묵 형성)
- 거리 척도:**
- Euclidean(L_2): $\sqrt{\sum (x_i - x_i')^2}$
 - Manhattan(L_1): $\sum |x_i - x_i'|$
 - Minkowski(L_p): $(\sum |x_i - x_i'|^p)^{1/p}$
 - Cosine: $1 - (x' \cdot x) / (\|x'\| \|x\|)$ — 방향 중시(텍스트/임베딩)

L18. k-NN 하이퍼파라미터-스케일

- **k=복잡도** 조절. 이진 = **출수 권장**(동점 회피)
 - **작은 k(k=1):** 저Bias/고Var, 노이즈 민감, 경계 복잡·뾰족
 - **큰 k:** 고Bias/저Var, 경계 매끄러움, 노이즈 둔감하나 경계 근처 오분류 가능. CV로 선택
 - **Feature Scaling 필수**(거리 기반): 스케일 큰 특징이 거리 지배
 - 표준화 Z-score: $(X - \mu) / \sigma$, 범위 비조정, 이상치 덜 민감
 - 정규화 Min-Max: $(X - \min) / (\max - \min)$, [0,1], 이상치 민감
- 차원의 저주: 차원 ↑ → 점 희소 → "최근접" 의미 약화, 성능 저하

L18. 결정트리 — 구성·예측

- **Root**(전체 데이터) · **Decision node**(특정 테스트) · **Branch**(테스트 결과) · **Leaf**(최종 예측)
- **예측:** root부터 특정 테스트 → 결과 분기 따라 이동 → leaf 도달=예측
- **학습(재귀적 분할):** **greedy** + recursive. 가장 순수한 자식을 만드는 분할 선택, 정지조건까지 반복

L18. 회귀 트리

- Leaf 예측 = 해당 샘플 **평균**
- $MSE = (1/N) \sum (y_i - y_{\text{mean}})^2$ (=분산)
- Weighted Child $MSE = \sum (|Child_i| / |Parent|) \cdot MSE(Child_i)$
- **MSE Reduction = MSE(Parent) - Weighted Child MSE** → 최대인 분할 선택

L18. 분류 트리 — 불순도 ★

- **Entropy** = $-\sum p_i \cdot \log_2(p_i)$, 범위 0(순수)~ $\log_2(C)$
- **Gini** = $1 - \sum p_i^2$, 범위 0(순수)~ $1 - 1/C$
- 예 [4R,2B]: Entropy=0.918, Gini=0.444
- Weighted Impurity = $\sum (|Child_i| / |Parent|) \cdot \text{Impurity}(Child_i)$
- **Information Gain**=Entropy(P) - WeightedEntropy(C)
- **Gini Gain**=Gini(P) - WeightedGini(C) → 최대 선택

L18. 가지치기(Pruning) · 장단점

- **Pre-pruning**(조기 종료): 최대 깊이, 최소 분할 샘플 수, 최소 leaf 샘플 수, 최소 불순도 감소
- **Post-pruning**(완전 성장 후):
Cost = Error + α ·Complexity. 비용 감소(또는 증가<임계값)면 가지치기. 더 효과적이나 계산 비쌈
- **Pros:** 해석 쉬움, 수치+범주 처리, 암묵적 특징 선택
- **Cons:** 과적합(pruning 필요), 불안정(작은 변화→다른 트리), 클래스 편향, **축평행(axis-parallel) 경계**, greedy(전역 최적 보장X)

L19. 지도 vs 비지도

지도=레이블 (x,y) 매핑 학습. **비지도**=레이블 없이 (x만) 내재 구조 발견. 예: 군집화, 차원축소, 이상탐지

L19. k-Means ★

- n개 점 → 사전 정의 **k개 비중점 군집**. 군집=centroid(평균), 가장 가까운 centroid에 할당(유클리드)
- **알고리즘:** ①k 선택 ②centroid 무작위 초기화 ③할당(최근접) ④갱신(할당점 평균) ⑤수렴까지 ③④ 반복
- **목적함수 WCSS(inertia)**= $\sum_i \sum_{x \in C_i} \|x - \mu_i\|^2$. 매 반복 감소/유지, **지역 최솟값만 보장**

L19. 초기화 · k 선택

- **초기화 민감:** 다른 초기화 → 다른 결과(지역최적)
 - **k-Means++:** 초기 centroid를 멀리 배치. ①첫 centroid 무작위 ②각 점의 최단거리 D, $D(x)^2$ 에 비례하는 확률로 선택(확률적 → 이상치 회피) ③표준 k-Means
 - **Elbow Method:** k=1~10 WCSS 계산 → k vs WCSS plot → 감소율 급격히 둔화되는 "elbow" (WCSS(k-1)-WCSS(k))/WCSS(k-1) < thr
- Cons:** k 사전 지정, 초기화·이상치 민감, 비볼록/밀도 다양·고차원에 약함

L19. DBSCAN ★ (밀도 기반)

- 군집=밀집 영역(희소 공간으로 분리). **임의 형태 군집 + 노이즈 식별**
- **하이퍼파라미터:** ϵ (이웃 반경), MinPts (core 최소 점수)
- **Core:** ϵ 내 MinPts 이상(자기 포함) · **Border:** core의 ϵ 내지만 자신은 core 아님 · **Noise:** 둘 다 아님(이상치)
- **알고리즘:** 미방문 P 선택 → ϵ 내 탐색 → core면 새 군집 시작 후 core 이웃으로 재귀 확장 / core 아니면 noise(후에 border 가능) → 전부 방문까지
- **Pros:** k 불필요, 임의 형태, 이상치 자동 식별. **Cons:** ϵ ·MinPts 민감, 밀도 크게 다른 군집 약함(하나의 ϵ 부적합), 고차원 약함

L19. 차원의 저주 · 축소

- 차원=특징 수 (집[크기,방수,나이,위치]=4D, 64×64 흑백=4096D)
- **저주:** 점 희소화 → 일반화 데이터 **지수 증가**, 거리 의미 약화(거리 등거리), 과적합·계산비용 ↑
- **Feature Selection:** 원래 특징의 부분집합(새 특징 X, 해석 유지) — Filter(중복 제거)/Wrapper(부분집합 탐색)/Embedded(L1, 트리 중요도)
- **Feature Extraction(Projection):** 특징 조합으로 새 특징 생성(해석 어려울 수 있음)

L19. PCA ★

- 선형·비지도. 최대 분산 방향의 **직교 주성분** 찾기. PC1=최대 분산, PC2⊥PC1=다음 최대... 상위 k개로 축소
- 분산 $\sigma^2 = (1/N) \sum (X_i - \mu)^2$; 공분산 $\text{cov}(X,Y) = (1/N) \sum (X_i - \mu_X)(Y_i - \mu_Y)$ (+동행, -역행, 0 무관)
- **공분산행렬 C:** d×d 대칭, 대각=분산, 비대각=공분산
- 주성분=C의 **고유벡터**(방향), **고유값 λ** =잡는 분산(중요도). $Cv = \lambda v$, $\det(C - \lambda I) = 0$
- **알고리즘:** ①표준화 $(X - \mu) / \sigma$ ②공분산행렬 ③고유벡터/값 ④ λ 내림차순 정렬 ⑤상위 k 선택 ⑥투영 $X_{\text{new}} = X_{\text{scaled}} \cdot W$ ($N \times k = N \times d \cdot d \times k$)
- **k 선택:** 설명분산비 $\lambda_i / \sum \lambda_i$, 누적 **85~95%**; Scree plot elbow; 시각화는 k=2,3
- **Cons:** 선형 가정(비선형 약함), 스케일 민감(표준화 필요), 해석 어려움

L19. t-SNE

비선형 차원축소, 주로 **시각화(2D/3D)**. **국소 구조 보존**(고차원 가까운 점 → 저차원 가까이). PCA보다 군집 분리가 뚜렷