

1. ML 기본 개념

- ML $\subset$ AI. 데이터에서 패턴·함수를 학습하여 결정
- 전통 프로그래밍: 규칙+데이터 $\rightarrow$ 답
- ML(지도): 데이터+답 $\rightarrow$ 규칙(모델) · 추론: 데이터+모델 $\rightarrow$ 답
- Tom Mitchell(1998): 경험 E, 작업 T, 성능척도 P로 학습
- 예(스팸분류): T=스팸/정상 분류, E=이메일 데이터, P=정확도

2. ML 분류(3대 패러다임)

- 지도학습: (x,y) 주어짐 $\rightarrow$ f: $x \rightarrow y$ 학습 (입력 $\rightarrow$ 레이블)
- 비지도학습: x만(레이블 없음) $\rightarrow$ 구조·패턴 발견
- 강화학습: 행동으로 누적 보상 최대화 정책 학습

예시

- 지도·CV: 이미지분류(x=픽셀,y=클래스), 객체탐지(y=클래스+박스)
- 지도·NLP: 기계번역(x=영어,y=한국어)
- 비지도: 이상탐지(outlier), LLM 사전학습=다음 단어 예측(레이블 불필요 $\rightarrow$ self-supervised)
- 강화: $s_t \rightarrow a_t \rightarrow r_t \rightarrow s_{t+1}$. 바둑(보상=승1/패0), Atari(보상=점수변화)

3. 회귀 vs 분류

- 핵심 차이 = 출력변수 형태
- 회귀: 연속 수치(가격·온도)
- 분류: 이산 범주(개/고양이, 합/불)

4. 단순 선형 회귀

- 가설(1입력): $\hat{y} = \theta_0 + \theta_1 x$ (θ_0, θ_1 =학습 파라미터)
- 잔차제곱합 $RSS = \sum_i (y^{(i)} - \hat{y}^{(i)})^2$
- $J(\theta_0, \theta_1) = (1/n) \sum_i (\theta_0 + \theta_1 x^{(i)} - y^{(i)})^2$
- 목표: J를 최소화하는 θ_0, θ_1
- J는 볼록(convex bowl) $\rightarrow$ 전역 최소값 보장 (선형회귀가 쉬운 이유)

5. 비용 최소화 2가지

- Closed-form(정규방정식): $\nabla J=0$ 풀이. 선형회귀엔 OK지만 일반화 X
- 경사하강(GD): 임의 θ 에서 시작해 내리막 이동. 미분가능 모든 비용(신경망 비볼록 포함)에 작동 $\rightarrow$ 일반화 O

6. 경사하강법 (Gradient Descent)

- $\theta_j := \theta_j - \alpha (\partial/\partial \theta_j) J(\theta_0, \theta_1)$
- α = 학습률(step size)
- 기울기 양수 $\rightarrow$ θ 감소 방향 / 음수 $\rightarrow$ θ 증가 방향
- α 너무 작음 $\rightarrow$ 느림 / 너무 큼 $\rightarrow$ 발산. 실무: $\alpha \in \{10^{-1}, 10^{-2}, \dots\}$ 시도 후 손실곡선 관찰
- 비볼록 J $\rightarrow$ 지역최소(local min)에 빠질 수 있음
- ★동시 업데이트(필수): temp0,temp1 먼저 계산 $\rightarrow \theta_0, \theta_1$ 한꺼번에 대입. 순차 대입은 오답

7. 회귀용 GD (편미분)

- $\theta_0 := \theta_0 - \alpha(2/n) \sum_i (\theta_0 + \theta_1 x^{(i)} - y^{(i)})$
- $\theta_1 := \theta_1 - \alpha(2/n) \sum_i (\theta_0 + \theta_1 x^{(i)} - y^{(i)}) \cdot x^{(i)}$
- $\rightarrow \theta_1$ 식에만 $\cdot x^{(i)}$ 가 붙는 점이 차이

8. 다중·다항 회귀

- 다중: $\hat{y} = \theta_0 + \theta_1 x_1 + \dots + \theta_d x_d$
- $\theta_j := \theta_j - \alpha(2/n) \sum_i (f_{\theta}(x^{(i)}) - y^{(i)}) \cdot x_j^{(i)}$
- 다항: $\hat{y} = \theta_0 + \theta_1 x + \theta_2 x^2 + \dots + \theta_m x^m \rightarrow$ 곡선 적합
- 고차수 $\rightarrow$ 과적합(overfitting) 위험
- 과적합=학습데이터엔 완벽, 새 데이터 일반화 실패

9. 분류 개요

- 범주형 레이블 예측 f: $x \rightarrow y \in \{1, \dots, K\}$
- 이진(K=2): 스팸/정상, 사기/정상
- 다중클래스(K>2): 상호배타 (개/고양이/말, 숫자 0-9)

10. 시그모이드(Sigmoid)

- $\sigma(z) = 1 / (1 + e^{-z})$
- 임의 실수 $z \rightarrow$ 출력 $\in (0,1)$ (확률로 해석)
- z 큼 $\rightarrow$ 1 근접, z 작음 $\rightarrow$ 0 근접, **z=0 $\rightarrow$ 0.5**
- 필요 성질: 유계[0,1]·신뢰도 해석가능·매끄럽고 미분가능

11. 로지스틱 회귀

- 이름은 회귀지만 분류 알고리즘 (선형모델+시그모이드)
- logit: $z = \theta^T x = \theta_0 + \theta_1 x_1 + \dots + \theta_d x_d$
- $f_{\theta}(x) = \sigma(\theta^T x) = P(y=1|x)$
- $1 - f_{\theta}(x) = P(y=0|x)$
- 임계값(0.5): $f_{\theta}(x) \geq 0.5 \rightarrow \hat{y}=1, <0.5 \rightarrow \hat{y}=0$
- 동치: $\theta^T x \geq 0 \rightarrow \hat{y}=1$
- 결정경계: $f=0.5 \Leftrightarrow \theta^T x=0 \rightarrow$ **x 공간에서 선형**

12. 로지스틱 비용 (BCE)

- $Cost = -y \cdot \log f_{\theta}(x) - (1-y) \cdot \log(1 - f_{\theta}(x))$
- y=1:** $-\log(f)$, $f \rightarrow 0$ 이면 비용 $\uparrow$
- y=0:** $-\log(1-f)$, $f \rightarrow 1$ 이면 비용 $\uparrow$
- 유래: 우도 최대화 $\Leftrightarrow$ 음의 로그우도 최소화 (Binary Cross-Entropy)
- $J(\theta) = (1/n) \sum_i Cost(f_{\theta}(x^{(i)}), y^{(i)})$

13. 로지스틱 GD 유도(연쇄법칙)

- $\partial J / \partial \theta_j = (\partial J / \partial f) \cdot (\partial f / \partial z) \cdot (\partial z / \partial \theta_j)$
- (a) $\partial J / \partial f = (f-y) / [f(1-f)]$
- (b) $\partial f / \partial z = f(1-f)$
- (c) $\partial z / \partial \theta_j = x_j$
- 곱하면 $\Rightarrow$ **$\partial J / \partial \theta_j = (f-y) \cdot x_j$**
- $\theta_j := \theta_j - \alpha(1/n) \sum_i (f_{\theta}(x^{(i)}) - y^{(i)}) \cdot x_j^{(i)}$
- 형태는 선형회귀와 동일! (모든 θ_j 동시 업데이트)

14. 다중클래스 (Softmax)

- 클래스별 파라미터 w_k , 점수 $z_k = w_k^T x$
- $softmax(z)_k = e^{z_k} / \sum_{j=1}^K e^{z_j}$
- 출력 $\in (0,1)$, **합 = 1** $\rightarrow$ 유효 확률분포
- $Cost = - \sum_{k=1}^K y_k \log(f_w(x)_k)$
- 교차엔트로피. y_k =정답1·오답0 (one-hot)

15. 평가지표 — 회귀

- MSE = $(1/N) \sum (y_i - \hat{y}_i)^2$
- RMSE = $\sqrt{MSE}$
- MAE = $(1/N) \sum |y_i - \hat{y}_i|$

16. 평가지표 — 이진분류

	예측 P	예측 N
실제 P	TP	FN
실제 N	FP	TN

- Accuracy** = $(TP+TN)/(TP+TN+FP+FN)$
- Precision** = $TP/(TP+FP)$ 예측양성 중 실제양성
- Recall**(=TPR) = $TP/(TP+FN)$ 실제양성 중 맞춘 것
- F1** = $2 \cdot (P \cdot R) / (P + R)$ P·R 조화평균

17. ROC / AUC

- TPR = $TP/(TP+FN)$, FPR = $FP/(FP+TN)$
- ROC:** 임계값 변화시키며 TPR vs FPR 곡선
- AUC**=곡선 아래 면적: **0.5=무작위, 1.0=완벽**
- 임계값 $\uparrow \rightarrow$ Recall $\downarrow$ (Precision $\uparrow$ 경향)
- 임계값 $\downarrow \rightarrow$ Recall $\uparrow$ (Precision $\downarrow$ 경향)

18. 평가지표 — 다중클래스

- Accuracy** = 맞은 예측 / 전체 예측
- 클래스별 $P_i = TP_i / (TP_i + FP_i)$, $R_i = TP_i / (TP_i + FN_i)$
- Macro:** 단순 산술평균 $(1/K) \sum P_i$ — 모든 클래스 동등
- Micro:** 전체 TP·FP·FN 합산 후 계산 $\rightarrow$ **Acc=P_{micro}=R_{micro}=F1_{micro}**
- Weighted:** 클래스 비율 w_i 가중평균 $\sum w_i \cdot P_i$