

3D Gaussian Splatting — 시험 대비 연습 문제

Lecture 10: Point-based Rendering to Gaussian Splatting · 계산 / 응용 / 고난도

Part 1. 계산 문제

Q1. Front-to-back Alpha Blending

한 픽셀에 세 개의 Gaussian splat이 카메라 가까운 쪽부터 정렬되어 있다.

- Splat 1: $\alpha_1 = 0.6$, $C_1 = 0.8$
- Splat 2: $\alpha_2 = 0.5$, $C_2 = 0.4$
- Splat 3: $\alpha_3 = 0.9$, $C_3 = 0.2$

(a) 최종 출력 색 C_{out} 과 남은 transmittance α_T 를 구하라.

(b) 만약 $\alpha_T < 0.05$ 이면 이후 layer 처리를 skip하는 early termination을 적용한다. Splat 3을 처리하는 단계까지 도달하는가?

(c) Splat 순서가 뒤집혔다면(즉, 가장 먼 것부터 처리) 같은 결과가 나오는가? 왜 sorting이 필요한가?

Q2. 정규화된 Splat Blending

픽셀 (x, y) 에 다음 splat들이 겹쳐 있다.

- Splat A: $c_A = 1.0$, $w_A = 0.3$
- Splat B: $c_B = 0.4$, $w_B = 0.5$
- Splat C: $c_C = 0.0$, $w_C = 0.2$

(a) 정규화된 색 $c(x, y) = \sum(c_i w_i) / \sum(w_i)$ 를 계산하라.

(b) 같은 색을 가진 영역인데 한쪽은 splat이 dense($\sum w = 1.5$), 다른 쪽은 sparse($\sum w = 0.3$)하다면, 정규화가 없을 때 어느 쪽이 더 어두워 보이는가?

Q3. SfM Point로부터 등방성 Gaussian 초기화

SfM이 점 $P = (0, 0, 0)$ 을 반환했고, 가장 가까운 세 이웃점은 다음과 같다.

- $P_1 = (1, 0, 0)$, $P_2 = (0, 2, 0)$, $P_3 = (0, 0, 2)$

(a) 평균 거리 d_{avg} 를 구하라.

(b) 초기 등방성 covariance matrix Σ 를 작성하라.

(c) 이웃점 P_1 이 $(5, 0, 0)$ 으로 갱신되면 Σ 는 어떻게 변하는가? 이것이 의미하는 바는?

Q4. 2D Multivariate Gaussian 값

$\mu = (1, 2)$, $\Sigma = \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}$ 일 때:

- (a) $x = (3, 2)$ 에서 $p(x; \mu, \Sigma)$ 를 구하라.
- (b) $x' = (1, 4)$ 에서 $p(x'; \mu, \Sigma)$ 를 구하라.
- (c) 두 점 모두 μ 로부터 Euclidean 거리가 2지만 확률 밀도가 다른 이유를 Mahalanobis 거리 관점에서 설명하라.

Q5. SH Coefficient 계산 (확장)

시점 방향 $\omega = (0, 1, 0)$ 에 대해 $R(\omega)$ 를 $l = 0, l = 1$ 두 band까지 계산하라. 계수 $C = [c_0, c_1, c_2, c_3] = [0.4, 0.3, -0.1, 0.2]$ 를 사용한다. (SH 기저는 강의 슬라이드 46의 표 참고)

- (a) Y_0, Y_1, Y_2, Y_3 의 값을 구하라.
- (b) $R(\omega)$ 를 계산하라.
- (c) $\omega' = (0, -1, 0)$ 에서 $R(\omega')$ 는 어떻게 달라지는가? 이것이 view-dependent color와 어떻게 관계되는가?

Q6. $\Sigma = RSS^T R^T$ 계산

3D Gaussian의 scale $S = \text{diag}(2, 1, 0.5)$ 이고, rotation R 은 z축 기준 90° 반시계 회전이다.

- (a) R 을 명시적으로 작성하라.
- (b) SS^T 를 구하라.
- (c) $\Sigma = RSS^T R^T$ 를 계산하라.
- (d) 이 Gaussian이 어느 방향으로 가장 길쭉한가?
- (e) SGD에서 Σ 를 직접 학습하지 않고 (q, s) 로 분해해 학습하는 이유 두 가지를 들어라.

Part 2. 응용 및 고난도 문제

Q7. Tile-based Rasterization 분석

이미지 해상도가 512×512 , tile 크기는 16×16 이다.

- (a) 전체 tile 수는?
- (b) 어떤 projected Gaussian이 중심 (50, 50), 반경 20 픽셀의 원으로 근사된다. 이 Gaussian이 overlap하는 tile의 수를 구하라.
- (c) L 리스트(Gaussian 참조 리스트)에 이 Gaussian은 몇 번 등장하는가?
- (d) Tile 크기를 32×32 로 키울 때 sorting 비용, GPU parallelism, blending time이 각각 어떻게 변하는가?

Q8. Adaptive Density Control 시나리오

각 상황에 대해 적절한 조치(Clone / Split / Prune / 조치 없음)와 이유를 답하라.

- (a) Gaussian의 opacity $\alpha = 0.0005$, 크기가 매우 큼.
- (b) 얇은 가지(branch)를 표현하는 한 Gaussian이 $\|S\| > \tau_s$ 이고 $\nabla_p L > \tau_p$ 이다.
- (c) 작은 Gaussian이 균일한 벽면 옆 빈 영역에 있다. $\nabla_p L > \tau_p$, $\|S\| < \tau_s$.
- (d) 한 Gaussian이 view frustum 바깥에 있다.

Q9. EWA Filtering 분석

EWA 식: $c(x, y) = \sum_k c_k r_k(m^{-1}(x, y)) \otimes h(x, y)$

- (a) 카메라가 가까워서 projected ellipse가 화면에서 매우 크다(magnification). r_k 와 h 중 어느 쪽이 resampling filter 모양을 지배하는가?
- (b) 카메라가 멀어서 surfel이 sub-pixel 크기로 보인다(minification). h (low-pass filter)를 적용하지 않으면 어떤 artifact가 발생하는가?
- (c) Gaussian이 "linear warping과 convolution에 대해 closed"라는 성질이 (a), (b)의 계산을 어떻게 단순화하는가?

Q10. 종합 응용 — 좁은 복도(Corridor) 재구성 (고난도)

일직선으로 50장의 사진을 찍어 좁은 복도를 3DGS로 재구성하려 한다.

- (a) 이 setup에서 SfM이 어려운 핵심 이유를 baseline/parallax 개념으로 설명하라.
- (b) 천장·바닥보다 양 옆 벽면 reconstruction이 더 잘 될지 더 못 될지 둘 다 가능성을 들어 논하라.
- (c) 평탄하지만 큰 벽면 영역에서 densification이 일어난다면 split과 clone 중 어느 쪽이 더 자주 발생할 것 같은가?

(d) 복도 끝에 거울이 있다면 vanilla 3DGS는 어떤 artifact를 만들 수 있는가? 강의 슬라이드 70(MirrorGaussian) 관점에서 완화책을 제시하라.

(e) View diversity가 제한된 이 setup에서 SH degree를 $l = 0$ 과 $l = 2$ 중 무엇으로 두는 것이 합리적인지 trade-off를 들어 논하라.

정답 및 해설

A1. Front-to-back Alpha Blending

(a) 초기: $C_{out} = 0, \alpha_T = 1$

- Splat 1: $C_{out} = 0 + (1)(0.6)(0.8) = \mathbf{0.48}, \alpha_T = 1 \times (1 - 0.6) = 0.4$
- Splat 2: $C_{out} = 0.48 + (0.4)(0.5)(0.4) = 0.48 + 0.08 = \mathbf{0.56}, \alpha_T = 0.4 \times 0.5 = 0.2$
- Splat 3: $C_{out} = 0.56 + (0.2)(0.9)(0.2) = 0.56 + 0.036 = \mathbf{0.596}, \alpha_T = 0.2 \times 0.1 = 0.02$

(b) Splat 3 직전 $\alpha_T = 0.2 > 0.05$ 이므로 처리 단계에 **도달**. 처리 후엔 $\alpha_T = 0.02$ 로 종료 조건 만족.

(c) 결과 다름. Front-to-back blending은 **비가환(non-commutative)**: 앞에 불투명한 splat이 있으면 뒤쪽 splat의 기여가 줄어든다. 그래서 depth 기준 sorting이 필수.

A2. 정규화된 Splat Blending

(a) $\sum c_i w_i = 0.3 + 0.2 + 0 = 0.5, \sum w_i = 1.0 \rightarrow \mathbf{c = 0.5}$

(b) 정규화 없으면 $c = \sum c_i w_i$ 만 사용. Dense 영역은 합이 커서 밝아 보이고 sparse 영역은 합이 작아 어두워 보인다. **Sparse 쪽이 더 어둡다**. 정규화는 splat 분포 불균일성에 의한 brightness 변동을 제거(슬라이드 17 chameleon 이미지가 같은 현상).

A3. 등방성 Gaussian 초기화

(a) 거리 = 1, 2, 2 $\rightarrow d_{avg} = (1 + 2 + 2)/3 = \mathbf{5/3 \approx 1.667}$

(b) $\Sigma = d_{avg}^2 \cdot I = (25/9) \cdot I = \mathbf{diag(25/9, 25/9, 25/9) \approx diag(2.78, 2.78, 2.78)}$

(c) 거리 = 5, 2, 2 $\rightarrow d_{avg} = 3, \Sigma = 9 \cdot I$. **Gaussian이 훨씬 커진다**. 이웃이 멀다는 건 그 영역의 sampling이 sparse하다는 의미이므로 더 큰 영역을 cover하는 게 합리적.

A4. 2D Multivariate Gaussian

일반식: $p(x) = 1/(2\pi|\Sigma|^{1/2}) \cdot \exp(-1/2(x - \mu)^T \Sigma^{-1} (x - \mu))$

$|\Sigma| = 4, |\Sigma|^{1/2} = 2, \Sigma^{-1} = \text{diag}(1/4, 1)$

(a) $x - \mu = (2, 0)$. Mahalanobis² = $(2)(1/4)(2) + 0 = 1$. $p = 1/(4\pi) \cdot e^{-0.5} \approx 0.0796 \cdot 0.6065 \approx \mathbf{0.0483}$

(b) $x' - \mu = (0, 2)$. Mahalanobis² = $0 + (2)(1)(2) = 4$. $p = 1/(4\pi) \cdot e^{-2} \approx 0.0796 \cdot 0.1353 \approx \mathbf{0.0108}$

(c) x축 분산 $\sigma_x^2 = 4$ 가 y축 분산 $\sigma_y^2 = 1$ 보다 4배 크다. 같은 Euclidean 거리라도 x축 방향이 "통계적으로" 더 가까움. Mahalanobis 거리는 covariance를 반영해 분산이 큰 축에서는 거리를 작게 평가.

A5. SH Coefficient 계산

$\omega = (0, 1, 0), r = 1.$

(a) $Y_0 = 1/(2\sqrt{\pi}), Y_1 = (1/2)\sqrt{(3/\pi)} \cdot (y/r) = (1/2)\sqrt{(3/\pi)}, Y_2 = (1/2)\sqrt{(3/\pi)} \cdot (z/r) = 0, Y_3 = (1/2)\sqrt{(3/\pi)} \cdot (x/r) = 0$

(b) $R(\omega) = 0.4 \cdot 1/(2\sqrt{\pi}) + 0.3 \cdot (1/2)\sqrt{(3/\pi)} + (-0.1)(0) + 0.2(0) = 0.2/\sqrt{\pi} + 0.15\sqrt{(3/\pi)} = (0.2 + 0.15\sqrt{3})/\sqrt{\pi} \approx (0.2 + 0.2598)/1.7725 \approx 0.2594$

(c) $\omega' = (0, -1, 0)$ 에선 Y_1 부호 반전. $R(\omega') = 0.2/\sqrt{\pi} - 0.15\sqrt{(3/\pi)} \approx -0.0337$. 같은 Gaussian이라도 시점에 따라 색이 변한다 — 이것이 view-dependent shading(반사·specular)을 표현하는 핵심. 음수 값은 실제 파이프라인에서 clamp 또는 sigmoid 후처리.

A6. $\Sigma = RSS^T R^T$

(a) $R = [[0, -1, 0], [1, 0, 0], [0, 0, 1]]$

(b) $SS^T = \text{diag}(4, 1, 0.25)$

(c) $R \cdot \text{diag}(4, 1, 0.25) \cdot R^T$ 를 계산. 중간 결과 $RD = [[0, -1, 0], [4, 0, 0], [0, 0, 0.25]]$. $RD \cdot R^T = \text{diag}(1, 4, 0.25)$

(d) 원래 S는 x방향(=2)이 가장 길었지만, z축 90° 회전 후 가장 큰 eigenvalue(4)가 y축으로 옮겨갔다. → y 방향으로 길쭉한 ellipsoid.

(e) ① 직접 학습하면 SGD가 indefinite/non-PSD 행렬을 만들어 invalid Gaussian이 됨. ② (q, s) 분해는 quaternion이 항상 valid rotation, s^2 이 항상 양수이므로 결과 Σ 가 항상 PSD. 추가로 자유도가 6개(q 3개 + s 3개)로 줄어 학습 안정.

A7. Tile-based Rasterization

(a) $(512/16)^2 = 32^2 = 1024$ 개 tile

(b) Ellipse가 차지하는 bbox: $x \in [30, 70], y \in [30, 70]$. Tile 인덱스: $x \rightarrow 30/16 = 1.875$ 부터 $70/16 = 4.375$ 까지 → col 1~4 (4개), 같은 방식으로 row 1~4. $4 \times 4 = 16$ 개 tile overlap

(c) DuplicateWithKeys 단계에서 각 overlap tile마다 entry 생성 → L에 16번 등장

(d) Tile 32×32 : 전체 tile 수 256개(↓) → sorting overhead 감소. 한 tile 안에 더 많은 splat → blending 직렬 비용 증가. GPU 병렬성 ↓ (활성 tile 수가 줄어 SM 활용도 저하). 작은 splat은 한두 tile에만 속해 L 길이 다소 짧아짐. Trade-off: tile 크기는 sorting cost와 parallelism의 균형점에서 결정. 보통 16×16 이 sweet spot.

A8. Adaptive Density Control

(a) Prune. $\alpha < \epsilon$ (≈ 0.001) 조건. Large도 동시에 만족 → 어쨌든 제거.

- (b) **Split (over-reconstruction)**. 큰 Gaussian이 thin structure를 못 표현 → 작게 쪼개야 detail 회복.
- (c) **Clone (under-reconstruction)**. 작은 Gaussian이지만 추가 coverage 필요 → 복제 후 이동.
- (d) **조치 없음**. Frustum culling은 rasterization 단계에서 처리. Density control 알고리즘은 본질적으로 view-independent라 frustum 밖 Gaussian도 다른 view에서 쓰일 수 있어 임의로 제거하지 않음.

A9. EWA Filtering

- (a) **Reconstruction kernel r_k** 가 지배. Magnification에서 projected ellipse가 low-pass filter보다 훨씬 커서 convolution 결과의 크기는 r_k 에 의해 결정. 이때 anti-aliasing보다 surface 보간이 중요.
- (b) Sub-pixel surfel에 low-pass 없이 r_k 만 적용하면, 한 surfel이 한 픽셀 미만의 frequency content를 가져 Nyquist를 초과. **Moiré, shimmering, flickering** 같은 aliasing 발생. h 가 highest frequency를 자르는 역할.
- (c) Gaussian이 convolution-closed라서 두 Gaussian의 결과는 또 다른 Gaussian이며 covariance는 단순 덧셈: $\Sigma_{\text{result}} = \Sigma_r + \Sigma_h$. Magnification($\Sigma_r \gg \Sigma_h$)에선 $\Sigma_{\text{result}} \approx \Sigma_r$, minification($\Sigma_r \ll \Sigma_h$)에선 $\Sigma_{\text{result}} \approx \Sigma_h$. → 별도 공식 없이 같은 Gaussian 식으로 모든 경우를 처리.

A10. 종합 응용 — 좁은 복도

- (a) 카메라가 거의 일직선으로 움직여 인접 view 간 **baseline(시점 차이)**이 매우 좁다. Triangulation은 baseline에 비례한 parallax가 있어야 깊이가 정확. Forward motion에선 카메라 광축과 평행한 방향의 ambiguity가 커서 depth 추정 부정확.
- (b) **잘 될 가능성**: 50장에 걸쳐 카메라가 다양한 위치에서 옆 벽을 보므로 각도 다양성이 천장/바닥보다 큼. **잘 안 될 가능성**: 벽 texture가 균일하면 feature matching 자체가 실패. 또한 벽이 카메라 광축과 거의 평행해 일부 view에선 grazing angle.
- (c) **Clone 우세**. 평탄한 벽은 detail이 많지 않지만 큰 면적을 cover해야 함 → under-reconstruction이 자주 발생. Split은 edge나 detail이 많은 곳(가구, 표지판)에서 일어남.
- (d) Vanilla 3DGS는 거울을 투명한 표면으로 학습하거나, 거울에 비친 가상 이미지를 거울 뒤쪽 floater Gaussian으로 표현하려 시도. 결과는 incoherent — 시점에 따라 깜빡이거나 거울 뒤에 유령 객체 출현. **완화책**: mirror plane을 명시적으로 모델링해 reflective surface를 가상 카메라로 처리 (MirrorGaussian의 접근), 또는 mirror region에 mask를 두어 학습에서 제외.
- (e) **$l = 0$** : 채널당 계수 1개. View diversity가 낮은 setup에서는 high-order SH가 overfit하기 쉬워 simpler model이 robust. 메모리도 적음. **$l = 2$** : 채널당 9개. View-dependent specular 표현 가능하지만, 같은 영역을 비슷한 각도에서만 본 데이터로는 high-order 계수가 noise에 fit돼 floater/색 artifact 유발. **결론**: 이 setup엔 **$l = 0$ 또는 $l = 1$** 이 합리적. 표면이 대부분 diffuse라면 $l = 0$ 으로 충분.