

Transformer 시험 예상 문제

COSE361 인공지능 — Lecture 25

Korea University · Computer Science and Engineering

출제 범위 & 학습 안내

RNN의 한계 → Attention → Self-attention → Encoder(Multi-head Attention, Add & Norm, Feed-Forward, Positional Encoding) → 학습/추론(Teacher Forcing) → Decoder(Masked Attention, Encoder-Decoder Attention) → 장단점까지 강의안 전 범위를 다룹니다.

구성: 진위형 10 · 객관식 5 · 단답형 8 · 계산 5 · 서술형 6 (총 34문항). **정답 및 해설**은 문제 뒤에 따로 있으니, 먼저 스스로 풀어본 뒤 확인하세요.

유형 1 · 진위형 (O/X)

다음 진술이 옳으면 O, 틀리면 X를 표시하고, 틀린 경우 그 이유를 간단히 적으시오.

1. RNN의 첫 번째 문제는 이전 문맥(previous context)이 고정 크기 벡터에 병목된다는 점이다. ()
2. Self-attention은 RNN 문제 (1)(병목)은 해결하지만, 문제 (2)(순차 계산으로 인한 병렬화 제약)는 해결하지 못한다. ()
3. Scaled dot-product attention에서 $\sqrt{d_k}$ 로 나누는 이유는, d_k 가 클 때 내적 값이 지나치게 커져 softmax가 한쪽으로 포화되고 gradient가 작아지는 현상을 완화하기 위해서이다. ()
4. Multi-head attention에서는 $d_{\text{model}} = d_v \times \text{num_heads}$ 관계가 성립한다. ()
5. Layer Normalization은 학습(training)과 추론(inference) 시 서로 다른 통계를 사용해 정규화 절차가 달라진다. ()
6. Positional Encoding은 입력 임베딩 벡터와 원소별 곱(element-wise multiply)으로 결합된다. ()
7. Decoder의 masked attention에서는 미래 단어 위치의 attention score에 음의 무한대($-\infty$)를 넣어, softmax 이후 그 가중치가 0이 되도록 만든다. ()
8. Encoder-Decoder attention에서 Query는 encoder로부터, Key와 Value는 decoder로부터 얻는다. ()
9. Self-attention의 계산·메모리 비용은 시퀀스 길이 n 에 대해 선형($O(n)$)으로 증가한다. ()
10. 학습 시에는 Teacher Forcing으로 디코더 입력을 한 번에 넣어 병렬 처리할 수 있지만, 추론 시에는 단어를 순차적으로(word by word) 생성한다. ()

유형 2 · 객관식

가장 적절한 보기를 하나 고르시오.

1. Self-attention에서 “정보를 모으려고 하는 주체(the element looking to gather information)”의 역할을 하는 것은?
(a) Query (b) Key (c) Value (d) FC weight W
2. Transformer가 sin/cos 기반 positional encoding을 사용하는 이유로 옳지 않은 것은?
(a) 위치마다 고유한 값을 가진다 (b) 값이 $[-1, 1]$ 로 유계이다
(c) 상대 위치(relative position)를 인코딩할 수 있다 (d) 학습해야 할 파라미터 수를 크게 늘려준다
3. Transformer의 Feed-Forward Network 구조로 옳은 것은?
(a) FC $\rightarrow$ FC (b) FC $\rightarrow$ 활성화함수 $\rightarrow$ FC
(c) 활성화함수 $\rightarrow$ FC $\rightarrow$ 활성화함수 (d) Attention $\rightarrow$ FC
4. Add & Norm에서 “Add”가 의미하는 연산은?
(a) 두 시퀀스를 이어 붙임(concatenation) (b) 잔차 연결(residual connection)
(c) attention score들의 합산 (d) 배치 차원 평균
5. 다음 중 Transformer의 단점에 해당하는 것은?
(a) 긴 시퀀스의 장거리 의존성 모델링에 약하다 (b) GPU 병렬화가 불가능하다
(c) attention 비용이 시퀀스 길이에 대해 $O(n^2)$ 로 증가한다 (d) 위치 정보가 전혀 필요 없다

유형 3 · 단답형

1. RNN의 두 가지 주요 문제점을 쓰시오.
2. Self-attention의 Query, Key, Value의 역할을 각각 한 줄로 설명하시오.
3. Scaled dot-product attention의 정의식 $\text{Attention}(Q, K, V) = ?$ 를 쓰시오.
4. Multi-head attention을 사용했을 때의 이점(왜 여러 개의 attention을 쓰는가)을 한 문장으로 쓰시오.
5. Positional Encoding의 짝수 차원($2i$)과 홀수 차원($2i + 1$)에 대한 두 정의식을 쓰시오.
6. Residual connection을 포함한 한 sublayer의 출력 $H(x) = ?$ 를 쓰시오. (Multi-head Attention 기준)
7. Layer Normalization에서 학습되는(learnable) 파라미터 두 개를 기호로 쓰시오.
8. Decoder의 디코딩 단계가 반복을 멈추는(생성을 종료하는) 조건은 무엇인가?

유형 4 · 계산 문제

C1. (Self-attention 계산) 입력 문장이 “I am a student”이고 $d_k = 64$ 이다. 단어 “student”의 Query Q_{student} 와 각 단어 Key의 내적이 아래와 같다.

$$Q_{\text{student}}^\top K_I = 16, \quad Q_{\text{student}}^\top K_{am} = 4, \quad Q_{\text{student}}^\top K_a = 4, \quad Q_{\text{student}}^\top K_{\text{student}} = 16$$

- (a) Scaling($/\sqrt{d_k}$) 후의 네 점수를 구하시오.
- (b) Softmax를 적용한 attention distribution을 구하시오. ($e^2 \approx 7.39$, $e^{0.5} \approx 1.65$ 사용)

(c) 최종 attention value를 $V_I, V_{am}, V_a, V_{student}$ 의 가중합 형태로 쓰시오.

C2. (차원 계산) $d_{\text{model}} = 512$, $\text{num_heads} = 8$ 인 multi-head attention이 있다.

(a) 각 head의 d_k 와 d_v 는?

(b) 시퀀스 길이가 10일 때, 한 head의 attention score 행렬 QK^T 의 크기(행×열)는?

(c) 모든 head의 출력을 concatenate한 행렬의 크기와, 최종 출력 사영 행렬 W^O 의 크기는?

C3. (Positional Encoding) $d_{\text{model}} = 4$ 일 때, 위치 $pos = 1$ 의 positional encoding 벡터 $PE(1) = [PE_{(1,0)}, \dots, PE_{(1,3)}]$ 의 각 성분을 강의안의 공식을 이용해 sin/cos 형태로 표현하시오. (여기서 두 번째 인덱스는 차원 번호이며 0부터 시작한다.)

C4. (복잡도) Self-attention에서 시퀀스 길이가 n 에서 $2n$ 으로 두 배가 되면, attention의 계산·메모리 비용은 몇 배가 되는가? 이유와 함께 설명하시오.

C5. (Masking) 길이가 4인 디코더 입력 ($\langle \text{sos} \rangle, je, suis, \text{étudiant} \rangle$)에 대한 masked self-attention의 attention score 행렬을 생각하자. 행은 Query 위치, 열은 Key 위치이다. masking으로 $-\infty$ 가 들어가는 (행, 열) 위치를 모두 나열하시오.

유형 5 · 서술형

1. Transformer에는 세 종류의 attention이 있다: (i) Encoder self-attention, (ii) Decoder masked self-attention, (iii) Encoder-Decoder attention. 각각에 대해 Query/Key/Value가 어디서 오는지, 그리고 masking이 적용되는지 여부를 비교하여 설명하시오.
2. Self-attention이 RNN의 문제 (1)(고정 크기 벡터 병목)을 어떻게 해결하는지 설명하시오.
3. Batch Norm, Layer Norm, Instance Norm을 “무엇을 기준으로 정규화하는가”의 관점에서 비교하고, Transformer가 Layer Norm을 채택하는 이유를 서술하시오.
4. 만약 Transformer에서 positional encoding을 제거한다면, 입력 “I am a student”와 “student a am I”에 대한 self-attention의 출력(집합)은 어떻게 되는가? 그 근본적인 이유(self-attention의 순열에 대한 성질)와 함께 설명하시오.
5. Transformer는 학습 시에는 병렬 처리가 가능하지만 추론 시에는 순차 처리해야 한다. 그 이유를 Teacher Forcing 및 masked attention과 연결하여 설명하시오.
6. Transformer의 장점 3가지와 단점 2가지를 각각 설명하시오.

정답 및 해설

유형 1 · 진위형

진위형 정답 요약

1	2	3	4	5	6	7	8	9	10
O	X	O	O	X	X	O	X	X	O

1. **[정답]** O. **[해설]** RNN은 이전 문맥 전체를 하나의 고정 크기 hidden state로 압축해 전달하므로, 정보 병목이 발생한다.
2. **[정답]** X. **[해설]** Self-attention은 두 문제를 모두 해결한다. 모든 토큰이 서로를 직접 참조하므로 병목(1)이 해소되고, 행렬 연산으로 한 번에 처리되므로 병렬화(2)도 가능하다.
3. **[정답]** O. **[해설]** d_k 가 크면 $Q^T K$ 의 분산이 커져 softmax 입력이 큰 값으로 치우치고, 출력이 0/1에 가깝게 포화되어 gradient가 소실된다. $\sqrt{d_k}$ 로 나눠 스케일을 안정화한다.
4. **[정답]** O. **[해설]** 각 head의 출력 차원이 d_v 이고 head가 num_heads개이므로, concatenation 결과가 $d_{\text{model}} = d_v \times \text{num_heads}$ 가 된다.
5. **[정답]** X. **[해설]** 학습/추론에서 절차가 달라지는 것은 Batch Norm이다(배치 통계 vs 이동평균). Layer Norm은 각 샘플 내부에서 정규화하므로 학습과 추론에서 동일한 절차를 사용한다 — 이것이 Layer Norm의 장점이다.
6. **[정답]** X. **[해설]** Positional encoding은 임베딩 벡터에 더해진다(add). 곱이 아니다.
7. **[정답]** O. **[해설]** 미래 위치에 $-\infty$ 를 넣으면 $e^{-\infty} = 0$ 이 되어 softmax 가중치가 0이 되고, 미래 단어를 참조하지 못한다.
8. **[정답]** X. **[해설]** 반대다. Query는 decoder에서, Key·Value는 encoder에서 온다. 디코더가 “무엇을 물을지(Q)”를 정하고, 인코더의 표현(K, V)에서 정보를 가져온다.
9. **[정답]** X. **[해설]** Self-attention은 모든 토큰 쌍에 대해 score를 계산하므로 비용이 시퀀스 길이의 제곱 $O(n^2)$ 로 증가한다.
10. **[정답]** O. **[해설]** 학습 시에는 정답(GT) 시퀀스 전체를 한 번에 입력(Teacher Forcing)해 병렬 처리하고, 추론 시에는 예측한 단어를 다시 입력으로 넣어 순차적으로 생성한다.

유형 2 · 객관식

객관식 정답

1. (a) 2. (d) 3. (b) 4. (b) 5. (c)

1. **[정답]** (a) Query. **[해설]** Query는 정보를 모으려는 주체, Key는 참조 대상의 특성, Value는 Key가 담고 있는 실제 정보다.
2. **[정답]** (d). **[해설]** sin/cos PE는 학습 파라미터가 없는 고정 함수다. (a)(b)(c)는 모두 사인파를 쓰는 실제 이유(위치마다 고유 $\cdot [-1, 1]$ 유계 $\cdot$ 상대 위치 인코딩 가능)이다.

3. [정답] (b). [해설] FFN은 $\text{FFN}(x) = \text{Activation}(xW_1 + b_1)W_2 + b_2$ 형태의 2층 MLP로, “FC → 활성화함수(ReLU 등) → FC” 구조다.
4. [정답] (b). [해설] $H(x) = x + \text{Sublayer}(x)$ 에서 입력 x 를 출력에 더하는 잔차(residual) 연결을 의미한다.
5. [정답] (c). [해설] Transformer의 대표적 단점은 attention의 $O(n^2)$ 비용과 많은 데이터 요구량이다. (a)(b)(d)는 모두 사실과 반대다(장점이거나 틀린 진술).

유형 3 · 단답형

1. [정답] (1) 이전 문맥이 고정 크기 벡터에 병목된다. (2) 순차 계산이 필요해 병렬화가 제한된다.
2. [정답] **Query**: 정보를 모으려는 주체. **Key**: 참조 후보가 될 수 있는 요소들의 특성. **Value**: Key 요소가 담고 있는 실제 정보.
3. [정답] $\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$
4. [정답] 서로 다른 표현 부분공간(representation subspace)의 정보에, 서로 다른 위치에서 동시에 주의를 기울일 수 있어 표현력이 높아진다.
5. [정답] $PE_{(pos, 2i)} = \sin(pos/10000^{2i/d_{\text{model}}})$, $PE_{(pos, 2i+1)} = \cos(pos/10000^{2i/d_{\text{model}}})$
6. [정답] $H(x) = x + \text{Multi-head Attention}(x)$
7. [정답] γ (scale)와 β (shift). 즉 $ln_i = \gamma \hat{x}_i + \beta$.
8. [정답] 다음 단어로 특수 토큰 [EOS](End of Sentence)가 예측될 때까지 반복한다.

유형 4 · 계산 문제

C1.

풀이

$\sqrt{d_k} = \sqrt{64} = 8$ 이므로:

(a) 스케일링 후 점수: $16/8 = 2$, $4/8 = 0.5$, $4/8 = 0.5$, $16/8 = 2$ 즉 $[2, 0.5, 0.5, 2]$.

(b) 분모 = $e^2 + e^{0.5} + e^{0.5} + e^2 \approx 7.39 + 1.65 + 1.65 + 7.39 = 18.08$.

$$\frac{7.39}{18.08} \approx 0.4, \quad \frac{1.65}{18.08} \approx 0.1, \quad \frac{1.65}{18.08} \approx 0.1, \quad \frac{7.39}{18.08} \approx 0.4$$

$\Rightarrow$ attention distribution $\approx [0.4, 0.1, 0.1, 0.4]$.

(c) attention value = $0.4 V_I + 0.1 V_{am} + 0.1 V_a + 0.4 V_{student}$.

(“I”와 “student”에 각각 0.4의 큰 가중치가 부여됨 — 동일/관련 단어에 강하게 주의.)

C2.

풀이

(a) $d_k = d_v = d_{\text{model}}/\text{num_heads} = 512/8 = 64$.

(b) Q 는 10×64 , $K^\top$ 는 64×10 이므로 $QK^\top$ 는 10×10 (시퀀스 길이 $\times$ 시퀀스 길이).

(c) 각 head 출력 a_i 는 10×64 . head가 8개이므로 concat 결과는 10×512 . 이를 다시 d_{model} 차원으로 사영하므로 W^O 의 크기는 $512 \times 512 (= d_{\text{model}} \times d_{\text{model}})$.

C3.

풀이

$d_{\text{model}} = 4$ 이면 차원쌍은 $i = 0$ (차원 0,1), $i = 1$ (차원 2,3)에 대응한다.

$$PE_{(1,0)} = \sin(1/10000^{0/4}) = \sin(1)$$

$$PE_{(1,1)} = \cos(1/10000^{0/4}) = \cos(1)$$

$$PE_{(1,2)} = \sin(1/10000^{2/4}) = \sin(1/100) = \sin(0.01)$$

$$PE_{(1,3)} = \cos(1/10000^{2/4}) = \cos(1/100) = \cos(0.01)$$

즉 $PE(1) = [\sin 1, \cos 1, \sin 0.01, \cos 0.01] \approx [0.841, 0.540, 0.010, 1.000]$.
(차원이 커질수록(= i 증가) 사인파의 파장이 길어져 천천히 변한다.)

C4.

풀이

4배가 된다. Self-attention은 모든 Query-Key 쌍에 대해 score를 계산하므로 연산·메모리가 $n \times n$, 즉 $O(n^2)$ 에 비례한다. 길이를 $2n$ 으로 늘리면 $(2n)^2 = 4n^2$ 이 되어 비용이 4배로 증가한다. (강의안 단점: $O(n^2)$)

C5.

풀이

위치를 $1=\langle \text{sos} \rangle$, $2=je$, $3=suis$, $4=\text{étudiant}$ 라 하자. Query 위치 i 는 자기 자신과 과거(열 $\leq i$)만 볼 수 있으므로, 열 $>$ 행인 상삼각(대각 제외) 위치에 $-\infty$ 가 들어간다:

$$(1, 2), (1, 3), (1, 4), (2, 3), (2, 4), (3, 4)$$

(총 6개. 강의안 그림의 검은색 칸과 일치.)

유형 5 · 서술형

1. [정답]

세 가지 attention 비교

종류	Query	Key / Value	Masking
(i) Encoder self-attn	Encoder	Encoder	없음
(ii) Decoder masked self-attn	Decoder	Decoder	있음(미래 차단)
(iii) Encoder-Decoder attn	Decoder	Encoder	없음

(i)은 입력 문맥 이해, (ii)는 미래 단어 누설 방지를 위해 causal mask 적용, (iii)은 디코더의 Query로 인코더 표현(K,V)에서 정보를 가져와 입력-출력을 연결한다.

2. [정답]

병목 해소 원리

RNN은 모든 과거 정보를 하나의 고정 크기 hidden state로 압축해 전달하므로, 시퀀스가 길어질수록 정보가 손실된다(병목). Self-attention에서는 각 출력 토큰이 모든 입력 토큰을 직접 참조하여,

관련도(attention weight)에 따라 필요한 정보를 가중합으로 직접 가져온다. 따라서 거리가 먼 토큰의 정보도 한 단계의 직접 연결로 접근할 수 있어 고정 크기 압축이 불필요해진다.

3. [정답]

정규화 비교

Batch Norm: 각 채널(C)별로 배치(N)와 공간(H,W) 차원에 걸쳐 정규화.

Layer Norm: 각 샘플(N)별로 채널(C)과 공간(H,W) 차원에 걸쳐 정규화.

Instance Norm: 각 (채널, 샘플)마다 공간(H,W) 차원에서만 정규화.

$$\hat{x}_{i,k} = \frac{x_{i,k} - \mu_i}{\sqrt{\sigma_i^2 + \epsilon}}, \quad \ln_i = \gamma \hat{x}_i + \beta.$$

Transformer가 Layer Norm을 쓰는 이유: 시퀀스 길이가 가변적이고 토큰마다 독립적으로 정규화해야 하므로, 배치 통계에 의존하는 Batch Norm은 부적합하다. Layer Norm은 각 토큰(샘플) 내부에서 정규화하므로 배치 크기·시퀀스 길이에 무관하고, 학습과 추론의 절차가 동일하다.

4. [정답]

Positional Encoding 제거 시

PE가 없으면 self-attention은 **순열 등변(permutation-equivariant)**이다. 즉 입력 순서를 바꿔도 출력의 집합(set)은 동일하고, 단지 같은 방식으로 재배열될 뿐이다. 따라서 “I am a student”와 “student a am I”는 (위치 정보가 없으므로) 본질적으로 같은 토큰 집합으로 취급되어, 출력 토큰의 집합이 동일해진다 — 모델이 어순을 구분하지 못한다. 이 때문에 위치 정보를 주입하는 positional encoding이 필요하다. (이 “순서 무관” 성질이 곧 강의안의 “input flexibility — 정렬되지 않은 집합도 처리 가능”의 근거다.)

5. [정답]

학습=병렬, 추론=순차

학습(Teacher Forcing): 정답(GT) 출력 시퀀스 전체를 디코더 입력으로 한 번에 넣으므로, 모든 위치의 예측을 동시에 계산할 수 있다(병렬). 단, 이때 각 위치가 미래 단어를 보지 못하도록 **masked attention**이 반드시 필요하다(보지 못하게 막아야 정직한 예측 학습이 됨).

추론: 정답을 모르므로, 이전 단계에서 예측한 단어를 다음 입력으로 넣어야 한다. 즉 t 번째 단어를 알아야 $t+1$ 번째를 예측할 수 있어 순차적으로 진행되며, [EOS]가 나올 때까지 반복한다.

6. [정답]

장점 3 · 단점 2

장점

- 긴 시퀀스에 강함: self-attention이 멀리 떨어진 토큰 간 관계도 직접(1-hop) 모델링.
- 높은 병렬성: 토큰을 동시에 처리 → GPU에서 훨씬 빠른 학습.
- 입력 유연성: 정렬된 시퀀스뿐 아니라 정렬되지 않은 집합(set)에도 적용 가능.

단점

- 높은 비용: attention의 연산·메모리가 시퀀스 길이에 대해 $O(n^2)$ 로 증가.
- 데이터 요구량: 효과적으로 학습하려면 보통 대규모 데이터가 필요(data hungry).