
인공지능 (COSE361)

시험 예상 문제집

Lecture 21: Deep Learning Basics

Lecture 22: Convolutional Neural Networks

개념 이해 · 계산 문제 · 종합 응용

활용 안내

- 총 **32문항**, 세 파트로 구성: **Part I 딥러닝 기초** / **Part II CNN** / **Part III 종합·응용**.
- 먼저 **문제만** 풀어본 뒤, 뒤쪽 **정답 및 해설**(p. 4 부터)에서 확인하세요.
- [개념] 서술형, [계산] 수치 계산, [O/X] 참거짓, [응용] 설계·비교 문제로 표기했습니다.
- 핵심 공식·그림은 강의안 표기를 그대로 따랐습니다.

Part I. 딥러닝 기초 (Lecture 21)

A. 개념 이해

문제 1. [개념] 인공지능(AI), 머신러닝(ML), 딥러닝(DL)의 포함 관계를 집합 관계로 나타내고, 세 개념을 각각 한 문장으로 정의하라.

문제 2. [개념] 활성화 함수가 왜 필요한지 설명하라. 특히 “비선형 활성화 함수 없이 선형 연산만 여러 번 쌓으면 단일 선형 연산과 같다”는 점을, 합성식 $a(cx + d) + b$ 를 전개하여 수식으로 보여라.

문제 3. [개념] Step function(계단 함수)을 활성화 함수로 사용할 수 없는 이유를 미분 관점에서 설명하라.

문제 4. [개념] 다음 네 활성화 함수의 미분(도함수)을 각각 적어라. (sigmoid는 $f = \sigma$, tanh는 $f = \tanh$ 로 표기)

$$(a) \text{ Sigmoid } \frac{1}{1 + e^{-x}} \quad (b) \text{ Tanh } \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (c) \text{ ReLU } \max(0, x) \quad (d) \text{ Step}$$

문제 5. [개념] 기울기 소실(Vanishing Gradient) 문제가 무엇인지 설명하고, ReLU가 sigmoid에 비해 이 문제를 완화하는 이유를 도함수의 형태를 근거로 서술하라.

문제 6. [개념] 과적합(Overfitting)이 무엇인지 학습 오차/테스트 오차 관점에서 정의하고, 강의에서 다룬 과적합 방지 기법을 3가지 이상 들고 각각 한 줄로 설명하라.

문제 7. [개념] Dropout의 학습(Training) 단계와 추론(Testing) 단계 동작이 어떻게 다른지 설명하라. 특히 추론 시 출력에 $(1 - p)$ 를 곱하는 이유는 무엇인가?

문제 8. [개념] L1 정규화와 L2 정규화의 비용 함수(Cost) 항을 각각 수식으로 쓰고, 두 기법의 차이를 설명하라.

문제 9. [개념] Gradient Descent(GD), Stochastic GD(SGD, 단일 샘플), Mini-batch SGD 세 가지를 “계산 비용”과 “기울기 추정의 정확도/노이즈” 측면에서 비교하라.

문제 10. [개념] Skip Connection(잔차 연결)이 깊은 신경망의 기울기 소실 문제를 어떻게 완화하는지, 그리고 잔차 블록의 출력 $H(x) = F(x) + x$ 가 갖는 의미를 설명하라.

B. 계산 문제

문제 11. [계산] AND 게이트를 구현하는 퍼셉트론의 가중치가 $w_1 = 1, w_2 = 1$, 편향 $b = -1.5$ 이고, $\sum w_i x_i + b \geq 0$ 이면 1, 아니면 0을 출력한다. 입력 $(x_1, x_2) \in \{(0, 0), (0, 1), (1, 0), (1, 1)\}$ 각각에 대해 가중합과 출력을 구하고, AND 진리표와 일치함을 보여라.

문제 12. [응용] 위와 같은 방식의 단일 퍼셉트론으로 NAND 게이트(AND의 부정)를 구현하려고 한다. 적절한 가중치 w_1, w_2 와 편향 b 를 하나 제시하고, 네 가지 입력에 대해 올바르게 동작함을 검증하라. (NAND 진리표: $(0, 0) \rightarrow 1, (0, 1) \rightarrow 1, (1, 0) \rightarrow 1, (1, 1) \rightarrow 0$)

문제 13. [계산] XOR 게이트가 단일 퍼셉트론으로 구현 불가능한 이유를 “선형 분리 가능성(linear separability)” 개념으로 설명하라. 그리고 이를 해결하기 위해 필요한 구조는 무엇인가?

문제 14. [계산] 아래는 XOR을 구현하는 다층 퍼셉트론(MLP)이다. 두 은닉 노드 h_1, h_2 와 출력 노드는 모두 ReLU를 활성화 함수로 쓴다.

$$h_1 = \text{ReLU}(1 \cdot x_1 + 1 \cdot x_2 + 0), \quad h_2 = \text{ReLU}(1 \cdot x_1 + 1 \cdot x_2 - 1), \quad \hat{y} = \text{ReLU}(1 \cdot h_1 - 2 \cdot h_2 + 0)$$

네 가지 입력 $(0, 0), (0, 1), (1, 0), (1, 1)$ 에 대해 $h_1, h_2, \hat{y}$ 를 모두 계산하고, XOR 진리표와 일치함을 확인하라.

문제 15. [계산] 다음과 같은 1-은닉층 신경망을 생각하자.

$$z = \sigma(W_1 x), \quad \hat{y} = W_2 \sigma(W_1 x) = W_2 z, \quad J = (\hat{y} - y)^2$$

연쇄 법칙(chain rule)을 사용하여 $\frac{\partial J}{\partial W_2}$ 와 $\frac{\partial J}{\partial W_1}$ 을 각각 유도하라. (sigmoid 도함수 $\sigma' = \sigma(1 - \sigma)$ 를 사용)

문제 16. [계산] 어떤 가중치 W 의 현재 값이 $W = 2.0$ 이고, 손실에 대한 기울기가 $\frac{\partial J}{\partial W} = 0.5$, 학습률 $\alpha = 0.1$ 이다. 경사하강법 갱신식 $W := W - \alpha \frac{\partial J}{\partial W}$ 에 따라 한 스텝 갱신된 W 값을 구하라. 또한 기울기가 양수일 때 W 가 증가/감소하는지 설명하라.

Part II. 합성곱 신경망 CNN (Lecture 22)

C. 개념 이해

문제 17. [개념] 이미지를 입력으로 쓸 때 Fully-Connected(FC) Layer가 갖는 두 가지 핵심 문제점을 설명하라.

문제 18. [개념] FC layer가 이미지에서 놓치는 지역성(Locality)과 이동 불변성(Translation Invariance)이 각각 무엇을 의미하는지 설명하라.

문제 19. [개념] Convolution layer의 가중치 공유(Weight Sharing)란 무엇이며, FC layer 대비 어떤 이점이 있는지 2가지 설명하라.

문제 20. [개념] Convolution에서 Padding을 사용하는 이유를 2가지 설명하라. (힌트: 출력 크기, 경계 픽셀)

문제 21. [개념] 커널 크기 K 에 대해 “SAME” padding 공식이 $P = \frac{K-1}{2}$ 인 이유를, stride $S = 1$ 일 때 출력 크기 공식 $\lfloor \frac{N+2P-K}{S} \rfloor + 1$ 에 대입하여 출력 크기 = 입력 크기가 됨을 보여라.

문제 22. [개념] Max Pooling과 Average Pooling의 차이를 설명하고, 각각 어떤 특성(prominent feature / smooth summary)을 보존하는지 서술하라.

문제 23. [O/X] “Pooling layer는 학습 가능한(learnable) 파라미터를 가진다.” 참/거짓을 판단하고, 그 이유를 설명하라. 또한 pooling이 작은 위치 변화에 대한 불변성을 주는 이유도 함께 적어라.

D. 계산 문제

문제 24. [계산] 출력 크기 공식 $\lfloor \frac{N+2P-K}{S} \rfloor + 1$ 을 사용하여 다음 각 경우의 출력 한 번의 크기를 구하라. (N : 입력 크기, P : 패딩, K : 커널, S : stride)

- (a) $N = 32, K = 5, P = 0, S = 1$ (conv)
- (b) $N = 224, K = 3, P = 1, S = 2$ (conv)
- (c) $N = 7, K = 3, P = 1, S = 1$ (conv, SAME)
- (d) $N = 28, K = 2, P = 0, S = 2$ (max pooling)

문제 25. [계산] Convolution layer의 학습 파라미터 수(편향 포함)를 구하라. 한 conv layer의 파라미터 수 = $(K \times K \times C_{in}) \times C_{out} + C_{out}$ 이다.

- (a) 입력 $32 \times 32 \times 3$, 필터 6개, 커널 5×5
- (b) 입력 $H \times W \times 64$, 필터 128개, 커널 3×3

문제 26. [계산] 입력 $32 \times 32 \times 3$ 이미지에 다음을 차례로 적용한다. 모두 padding 없음($P=0$), stride 1 이다. 각 단계 출력의 공간 크기와 채널 수를 ($H \times W \times C$) 형태로 추적하라.

- (1) Conv: $5 \times 5 \times 3$ 필터 6개 + ReLU
- (2) Conv: $5 \times 5 \times 6$ 필터 10개 + ReLU

문제 27. [계산] VGGNet의 핵심 주장: “ 3×3 합성곱을 여러 개 쌓는 것이 큰 커널보다 유리하다.” 입력·출력 채널이 모두 C 일 때,

(a) 3×3 conv 3개를 쌓을 때의 총 파라미터 수(편향 무시)

(b) 7×7 conv 1개의 파라미터 수(편향 무시)

를 각각 C 에 대한 식으로 구하고, 유효 수용 영역(receptive field)이 동일함을 설명하라.

문제 28. [계산] stride 1, padding 없는 3×3 convolution을 n 개 연속으로 쌓았을 때, 첫 입력 기준 유효 수용 영역(receptive field)의 한 변 크기를 n 의 식으로 나타내라. ($n = 1, 2, 3$ 일 때 값도 함께 제시)

Part III. 종합 · 응용

문제 29. [응용] AlexNet, VGGNet, ResNet의 핵심 아이디어를 비교하는 표의 빈칸을 채워라. (계층 수, 핵심 기여, 대표 기법)

모델	핵심 기여	대표 기법/특징
AlexNet	?	?
VGGNet	?	?
ResNet	?	?

문제 30. [응용] ResNet 논문에서, “plain” 네트워크의 층을 무작정 깊게 쌓았더니 56층 모델이 20층 모델보다 학습 오차와 테스트 오차 모두 더 나뉘었다. (a) 이 현상이 과적합 때문이 아닌 이유는 무엇인가? (b) 저자들이 제시한 가설은 무엇이며, (c) 잔차 연결이 이를 어떻게 해결하는지 설명하라.

문제 31. [응용] ResNet의 bottleneck 블록(ResNet-50/101/152)은 $1 \times 1 \rightarrow 3 \times 3 \rightarrow 1 \times 1$ 구조를 쓴다. 여기서 1×1 convolution의 역할은 무엇이며, 왜 이런 구조가 연산량 측면에서 유리한지 설명하라.

문제 32. [계산] 입력 $32 \times 32 \times 3$ 에 대해 다음 미니 CNN을 통과시킨다. 각 단계 출력의 ($H \times W \times C$)를 구하라.

(1) Conv: 3×3 필터 16개, SAME padding($P = 1$), stride 1, + ReLU

(2) Max Pool: $K = 2, S = 2$

(3) Conv: 3×3 필터 32개, SAME padding($P = 1$), stride 1, + ReLU

(4) Max Pool: $K = 2, S = 2$

마지막으로 이 결과를 Flatten 했을 때 벡터의 길이는 얼마인가?

정답 및 해설

Part I. 딥러닝 기초

문제 1. AI/ML/DL 포함 관계

해설 — 문제 1

포함 관계: **AI** $\supset$ **ML** $\supset$ **DL** (AI가 가장 넓고, 그 부분집합이 ML, 다시 그 부분집합이 DL).

- **인공지능(AI)**: 컴퓨터가 인간의 지능을 모방하도록 하는 가장 넓은 개념의 모든 기법.
- **머신러닝(ML)**: AI의 부분집합으로, 명시적으로 프로그래밍하지 않고 데이터로부터 패턴을 학습하는 알고리즘.
- **딥러닝(DL)**: ML의 부분집합으로, 인공신경망(여러 층)을 이용해 데이터로부터 표현(representation)을 학습하는 알고리즘.

문제 2. 활성화 함수의 필요성

해설 — 문제 2

활성화 함수의 목적은 **비선형성(non-linearity)**을 부여하는 것이다. 비선형 활성화가 없으면 층을 아무리 깊게 쌓아도 하나의 선형 변환과 동일하다:

$$a(cx + d) + b = acx + ad + b = Ax + B \quad (A = ac, B = ad + b)$$

즉 두 번의 선형 연산을 합성해도 결국 $Ax + B$ 형태의 단일 선형 함수가 되어, XOR처럼 선형 분리가 불가능한 문제를 풀 수 없다. 비선형 활성화를 넣어야 **임의의 복잡한 함수(곡선 형태의 결정경계)**를 근사할 수 있다.

문제 3. Step function을 쓸 수 없는 이유

해설 — 문제 3

계단 함수의 도함수는

$$f'(x) = \begin{cases} 0 & x \neq 0 \\ \text{정의 안 됨(nan)} & x = 0 \end{cases}$$

즉 **거의 모든 지점에서 기울기가 0**이다. 신경망은 역전파에서 기울기를 곱해가며 가중치를 갱신하는데, 기울기가 0이면 가중치 업데이트량도 0이 되어 **학습 자체가 불가능**하다. (강의안: “Zero gradient everywhere”)

문제 4. 네 활성화 함수의 도함수

해설 — 문제 4

- (a) Sigmoid: $f'(x) = f(x)(1 - f(x))$
- (b) Tanh: $f'(x) = 1 - f(x)^2$
- (c) ReLU: $f'(x) = \begin{cases} 1 & x > 0 \\ 0 & x < 0 \\ \text{nan} & x = 0 \end{cases}$

- (d) Step: $f'(x) = \begin{cases} 0 & x \neq 0 \\ \text{nan} & x = 0 \end{cases}$

✓ Sigmoid, Tanh, ReLU는 활성화로 사용 가능(✓), Step은 기울기가 0이라 사용 불가(✗).

문제 5. 기울기 소실과 ReLU

해설 — 문제 5

기울기 소실: 역전파에서 출력층에서 입력층 쪽으로 갈수록 기울기가 점점 작아져 0에 가까워지는 현상. 입력 가까운 층의 가중치가 거의 갱신되지 않아 학습이 어려워진다.

원인(sigmoid): sigmoid 도함수 $\sigma' = \sigma(1 - \sigma)$ 의 최댓값은 0.25 이며, 양 끝(포화 영역)에서는 거의 0이다. 여러 층을 거치며 0.25 이하의 값이 계속 곱해지면 기울기가 지수적으로 소실된다.

ReLU의 완화: ReLU의 도함수는 $x > 0$ 에서 **항상 1**이다. 활성화 영역에서 기울기가 1로 유지되므로 여러 층을 곱해도 기울기가 줄어들지 않아 소실이 완화된다.

문제 6. 과적합과 방지법

해설 — 문제 6

과적합: 모델이 학습 데이터에 지나치게 맞춰져, 학습 오차는 작지만 테스트 오차는 큰 상태(일반화 실패).

방지 기법(강의 기준):

- **Data Augmentation:** 회전·반전·밝기·노이즈·crop 등 변환으로 학습 데이터를 인위적으로 늘려 다양성 확보.
- **Dropout:** 학습 중 은닉 노드의 일부를 확률적으로 꺼서 특정 뉴런 의존을 방지.
- **Loss Regularization (L1/L2):** 손실에 가중치 크기에 대한 패널티 항을 더해 과도하게 큰 가중치를 억제.

문제 7. Dropout의 학습/추론 차이

해설 — 문제 7

- **학습 단계:** 각 뉴런을 확률 p 로 무작위로 비활성화(drop). 매 스텝마다 서로 다른 부분 네트워크가 학습됨.
- **추론 단계:** 모든 뉴런을 활성화하되, 출력에 $(1 - p)$ 를 곱해 스케일을 맞춤.

$(1 - p)$ 를 곱하는 이유: 학습 시에는 평균적으로 비율 $(1 - p)$ 만큼의 뉴런만 켜져 있었으므로, 추론에서 모든 뉴런을 켜면 입력 합이 학습 때보다 평균적으로 $1/(1 - p)$ 배 커진다. 이를 보정해 **학습/추론 시기댓값(스케일)을 일치**시키기 위함이다.

문제 8. L1 vs L2 정규화

해설 — 문제 8

$$\text{L1: Cost} = \sum_i \left(y_i - \sum_j x_{ij} W_j \right)^2 + \lambda \sum_j |W_j|$$

$$\text{L2: Cost} = \sum_i \left(y_i - \sum_j x_{ij} W_j \right)^2 + \lambda \sum_j W_j^2$$

차이: L1은 가중치의 절댓값 합을 패널티로 주어 일부 가중치를 정확히 0으로 만드는 **희소성(sparsity)**

유도(특징 선택 효과). L2는 제곱 합을 패널티로 주어 가중치를 전반적으로 **작게(0에 가깝게)** 만들지만 정확히 0으로 만들지는 않는다. λ 는 정규화 강도를 조절하는 하이퍼파라미터.

문제 9. GD / SGD / Mini-batch 비교

해설 — 문제 9

방식	1회 갱신에 쓰는 데이터	계산 비용	기울기 추정
GD	전체 데이터셋	매우 큼(느림)	정확(노이즈 없음)
SGD(단일)	데이터 1개	작음(빠름)	매우 noisy(불안정)
Mini-batch	B개 묶음	중간	효율적이며 참 기울기에 가까운 좋은 추정

GD는 매 갱신마다 전체 데이터를 써서 정확하지만 계산량이 큼. SGD는 빠르지만 노이즈가 큼. Mini-batch는 둘의 절충으로, 효율적이면서도 참 기울기의 더 나은 추정을 제공한다(실무 표준).

문제 10. Skip Connection의 원리

해설 — 문제 10

Skip(잔차) 연결은 어떤 층의 **입력을 출력에 직접 더해주는 지름길**이다. 출력은 $H(x) = F(x) + x$ 로 표현된다.

- **기울기 흐름**: 덧셈 연산을 통해 기울기가 중간 층을 건너뛰어 입력 쪽으로 곧바로 흐를 수 있는 경로가 생기므로, 기울기 소실이 완화된다.
- **항등 사상 학습**: 추가된 층이 불필요하면 $F(x) \approx 0$ 으로 만들어 $H(x) \approx x$ (항등 사상)를 쉽게 학습할 수 있다. 따라서 깊은 모델이 최소한 얇은 모델만큼은 성능을 낼 수 있도록 보장한다.

문제 11. AND 게이트 검증

해설 — 문제 11

$w_1 = w_2 = 1, b = -1.5$, 임계 $\sum w_i x_i + b \geq 0 \Rightarrow 1$:

x_1	x_2	가중합 $x_1 + x_2 - 1.5$	출력	AND 정답
0	0	-1.5	0	0✓
0	1	-0.5	0	0✓
1	0	-0.5	0	0✓
1	1	0.5	1	1✓

모든 입력에서 AND 진리표와 일치한다. 결정경계는 $x_1 + x_2 - 1.5 = 0$.

문제 12. NAND 게이트 설계

해설 — 문제 12

AND의 가중치/편향의 **부호를 모두 뒤집으면** NAND가 된다. 예: $w_1 = -1, w_2 = -1, b = 1.5$.

x_1	x_2	가중합 $-x_1 - x_2 + 1.5$	출력	NAND 정답
0	0	1.5	1	1✓
0	1	0.5	1	1✓
1	0	0.5	1	1✓
1	1	-0.5	0	0✓

($w_1 = w_2 = -2$, $b = 3$ 등 부호만 맞으면 다른 답도 가능.)

문제 13. XOR이 단일 퍼셉트론으로 불가능한 이유

해설 — 문제 13

단일 퍼셉트론의 결정경계는 **하나의 직선(초평면)**이며, 이 직선 한쪽은 1, 반대쪽은 0으로만 나눌 수 있다(**선형 분리**). 그러나 XOR은 출력 1인 점 (0, 1), (1, 0) 과 출력 0인 점 (0, 0), (1, 1) 이 대각선으로 엇갈려 배치되어, 어떤 직선으로도 둘을 분리할 수 없다(AND·OR은 가능, XOR은 불가능).

해결: 은닉층을 추가한 **다층 퍼셉트론(MLP)** 을 쓰면 된다. 비선형 활성화를 가진 은닉층이 입력을 선형 분리 가능한 공간으로 변환해 준다.

문제 14. XOR MLP 계산

해설 — 문제 14

$h_1 = \text{ReLU}(x_1 + x_2)$, $h_2 = \text{ReLU}(x_1 + x_2 - 1)$, $\hat{y} = \text{ReLU}(h_1 - 2h_2)$:

x_1	x_2	h_1	h_2	$\hat{y} = \text{ReLU}(h_1 - 2h_2)$	XOR 정답
0	0	$\text{ReLU}(0) = 0$	$\text{ReLU}(-1) = 0$	$\text{ReLU}(0 - 0) = 0$	0 ✓
0	1	$\text{ReLU}(1) = 1$	$\text{ReLU}(0) = 0$	$\text{ReLU}(1 - 0) = 1$	1 ✓
1	0	$\text{ReLU}(1) = 1$	$\text{ReLU}(0) = 0$	$\text{ReLU}(1 - 0) = 1$	1 ✓
1	1	$\text{ReLU}(2) = 2$	$\text{ReLU}(1) = 1$	$\text{ReLU}(2 - 2) = 0$	0 ✓

네 입력 모두 XOR 진리표와 정확히 일치한다. 핵심 아이디어: h_2 는 (1, 1) 일 때만 켜져서, 출력에서 $-2h_2$ 로 (1, 1) 의 값을 끌어내려 0을 만든다.

문제 15. 역전파 유도

해설 — 문제 15

(1) W_2 에 대한 기울기 ($\hat{y} = W_2 z$, $z = \sigma(W_1 x)$):

$$\frac{\partial J}{\partial W_2} = \frac{\partial J}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial W_2} = 2(\hat{y} - y) \cdot z = 2(\hat{y} - y) \sigma(W_1 x)$$

(2) W_1 에 대한 기울기 (연쇄: $J \rightarrow \hat{y} \rightarrow z \rightarrow W_1$):

$$\frac{\partial J}{\partial W_1} = \frac{\partial J}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial z} \frac{\partial z}{\partial W_1} = 2(\hat{y} - y) \cdot W_2 \cdot \underbrace{z(1-z)}_{\sigma'(W_1 x)} \cdot x$$

여기서 $\frac{\partial \hat{y}}{\partial z} = W_2$, $\frac{\partial z}{\partial W_1} = \sigma'(W_1 x) \cdot x = z(1-z)x$ 를 사용했다.

문제 16. 경사하강법 한 스텝

해설 — 문제 16

$$W := W - \alpha \frac{\partial J}{\partial W} = 2.0 - 0.1 \times 0.5 = 2.0 - 0.05 = \boxed{1.95}$$

기울기가 **양수**이면 갱신식에서 $-\alpha$ (양수) 만큼 빼므로 W 는 **감소**한다. 이는 손실이 증가하는 방향(기울기의 양의 방향)의 반대로 이동해 손실을 줄이려는 것이다.

Part II. 합성곱 신경망 CNN

문제 17. FC layer의 두 문제점

해설 — 문제 17

1. **많은 파라미터 수**: 모든 입력-출력을 연결하므로 가중치가 매우 많아 메모리·연산 비용이 크다. (예: 입력 1024, 출력 128이면 $\mathbf{W} \in \mathbb{R}^{128 \times 1024}$.)
2. **공간 정보 손실**: 이미지를 1차원으로 flatten 하면 픽셀 간 공간 구조(지역성, 이동 불변성)가 사라진다.

문제 18. Locality와 Translation Invariance

해설 — 문제 18

- **지역성(Locality)**: 가까이 있는 픽셀/특징이 멀리 있는 것보다 더 강하게 연관되어 있다는 성질. FC는 flatten 후 모든 픽셀을 동등하게 연결해 이 국소 구조를 무시한다.
- **이동 불변성(Translation Invariance)**: 어떤 패턴(예: 고양이)이 이미지 내에서 위치가 바뀌어도 그 의미는 거의 변하지 않는다는 성질. FC layer에서는 같은 패턴이 다른 위치에 있으면 완전히 다른 입력으로 인코딩되어 버린다.

문제 19. Weight Sharing의 의미와 이점

해설 — 문제 19

가중치 공유: 하나의 필터(커널)를 이미지의 모든 위치에 동일하게 적용하는 것. 즉 영역마다 다른 가중치를 쓰지 않고 **같은 가중치 집합을 반복 사용**한다.

이점:

- **파라미터 수 대폭 감소**: 작은 커널 하나의 가중치만 학습하면 되므로 FC 대비 파라미터가 훨씬 적다.
- **이동 불변성/지역 특징 추출**: 같은 필터가 위치에 무관하게 동일한 국소 패턴(엣지 등)을 검출하므로, 위치가 바뀐 동일 패턴도 잘 잡아낸다.

문제 20. Padding이 필요한 이유

해설 — 문제 20

1. **공간 크기 감소 방지**: 패딩이 없으면 합성곱마다 출력이 작아진다(예: 32×32 에 $5 \times 5 \rightarrow 28 \times 28$, 층을 거듭하면 너무 빨리 줄어 깊은 망 구성이 어려움). 패딩으로 크기를 유지할 수 있다.
2. **경계 정보 손실 방지**: 패딩이 없으면 가장자리 픽셀은 중심 픽셀보다 훨씬 적게 사용되어 경계 정보가 손실된다. 패딩이 가장자리도 충분히 활용되게 한다.

문제 21. SAME padding 공식 유도

해설 — 문제 21

$S = 1$ 일 때 출력 크기 공식에 $P = \frac{K-1}{2}$ 를 대입:

$$\left\lfloor \frac{N + 2P - K}{S} \right\rfloor + 1 = \left\lfloor \frac{N + 2 \cdot \frac{K-1}{2} - K}{1} \right\rfloor + 1 = \lfloor N + (K-1) - K \rfloor + 1 = (N-1) + 1 = N$$

따라서 출력 크기 = 입력 크기 N 이 되어 **공간 크기가 보존**된다. (홀수 커널이어야 P 가 정수가 되어 짝

끔한 중심을 가짐.)

문제 22. Max vs Average Pooling

해설 — 문제 22

- **Max Pooling:** 각 패치에서 **최댓값**을 선택. 가장 두드러진 특징(prominent feature)을 보존 → 강한 활성화(엣지·질감 등)를 유지.
- **Average Pooling:** 각 패치 값들의 **평균**을 계산. 부드러운 요약(smooth summary)을 생성 → 전반적 분포를 완만하게 표현.

공통점: 출력 채널 수 = 입력 채널 수, 학습 파라미터 없음.

문제 23. Pooling은 파라미터를 갖는가? (O/X)

해설 — 문제 23

거짓(X). Pooling은 단순히 max 또는 average 같은 고정된 연산만 수행하므로 **학습 가능한 파라미터가 없다** (“No learnable parameters”).

위치 불변성을 주는 이유: 패치 내에서 최댓값(또는 평균)을 취하면, 특징의 위치가 패치 내부에서 조금 이동해도 출력값은 거의 동일하게 유지된다. 따라서 작은 공간 이동에 대한 불변성(invariance to small spatial shifts)을 얻는다.

문제 24. 출력 크기 계산

해설 — 문제 24

공식 $\lfloor \frac{N+2P-K}{S} \rfloor + 1$:

(a) $\frac{32+0-5}{1} + 1 = 27 + 1 = \boxed{28}$

(b) $\frac{224+2-3}{2} + 1 = \frac{223}{2} + 1 = \lfloor 111.5 \rfloor + 1 = 111 + 1 = \boxed{112}$

(c) $\frac{7+2-3}{1} + 1 = 6 + 1 = \boxed{7}$ (입력과 동일 → SAME)

(d) $\frac{28-2}{2} + 1 = 13 + 1 = \boxed{14}$ (풀링: 절반으로 다운샘플)

문제 25. Conv 파라미터 수

해설 — 문제 25

파라미터 수 = $(K \times K \times C_{in}) \times C_{out} + C_{out}$:

(a) $(5 \times 5 \times 3) \times 6 + 6 = 75 \times 6 + 6 = 450 + 6 = \boxed{456}$

(b) $(3 \times 3 \times 64) \times 128 + 128 = 576 \times 128 + 128 = 73,728 + 128 = \boxed{73,856}$

(주의: 파라미터 수는 입력의 공간 크기 H, W 와 무관하며, 커널 크기·채널 수에만 의존한다.)

문제 26. Multiple channel 흐름 추적

해설 — 문제 26

$P = 0, S = 1$ 이므로 각 conv마다 한 번이 $K - 1 = 4$ 씩 감소, 출력 채널 = 필터 개수:

(1) $32 \times 32 \times 3 \rightarrow (32 - 5 + 1) = 28 \Rightarrow \boxed{28 \times 28 \times 6}$

$$(2) 28 \times 28 \times 6 \rightarrow (28 - 5 + 1) = 24 \Rightarrow 24 \times 24 \times 10$$

필터의 채널 깊이는 항상 입력 채널 수와 같아야 함($5 \times 5 \times 3$, 그다음 $5 \times 5 \times 6$). 출력의 채널 수는 필터 개수로 결정된다.

문제 27. $3 \times (3 \times 3)$ vs 7×7

해설 — 문제 27

편향 무시, 입력·출력 채널 모두 C :

$$(a) 3 \times 3 \text{ conv } 3\text{개}: 3 \times (3 \times 3 \times C \times C) = 3 \times 9C^2 = 27C^2$$

$$(b) 7 \times 7 \text{ conv } 1\text{개}: 7 \times 7 \times C \times C = 49C^2$$

수용 영역: stride 1 기준 3×3 conv 하나는 수용 영역을 +2 늘린다. 3개를 쌓으면 $3 \rightarrow 5 \rightarrow 7$ 로 7×7 와 동일한 유효 수용 영역을 갖는다.

결론: 같은 수용 영역을 더 적은 파라미터($27C^2 < 49C^2$) 로 달성하며, 사이사이 ReLU가 들어가 비선형성이 더 많아져 표현력이 좋아진다.

문제 28. Receptive field 일반식

해설 — 문제 28

stride 1, 3×3 conv는 한 층마다 수용 영역을 양쪽으로 1씩(총 2) 키운다. 첫 층이 3이므로 n 개 쌓으면

$$RF = 3 + 2(n - 1) = 2n + 1$$

$$n = 1 \rightarrow 3 \times 3, n = 2 \rightarrow 5 \times 5, n = 3 \rightarrow 7 \times 7.$$

Part III. 종합 · 응용

문제 29. AlexNet/VGGNet/ResNet 비교

해설 — 문제 29

모델	핵심 기여	대표 기법/특징
AlexNet	ImageNet(ILSVRC'12) 최초 우승 CNN; 딥러닝 부흥의 신호탄	8층(conv 5 + FC 3), ReLU·Dropout·Max Pooling 도입, GPU 학습
VGGNet	깊이(depth)가 성능 향상의 핵심임을 강조	16층(conv 13 + FC 3), 작은 3×3 커널을 깊게 stacking
ResNet	매우 깊은 망(152층+)의 학습 가능하게 함	잔차 연결(Residual/Skip Connection) $H(x) = F(x) + x$, basic/bottleneck 블록

문제 30. ResNet 깊이 문제와 잔차의 해결

해설 — 문제 30

(a) **과적합이 아닌 이유:** 과적합이라면 학습 오차는 낮고 테스트 오차만 높아야 한다. 그러나 56층 모델은 학습 오차마저 20층보다 높았다. 즉 일반화 문제가 아니라 학습(최적화) 자체가 안 되는 문제다.

(b) **가설:** 깊은 모델은 최적화가 더 어렵다(**optimization difficulty**).

(c) **잔차 연결의 해결:** 블록이 항등 사상 $H(x) = x$ 를 쉽게 학습할 수 있도록 $H(x) = F(x) + x$ 구조

를 도입($F(x) \rightarrow 0$ 이면 항등). 이로써 **깊은 모델이 최소한 얇은 모델만큼은 성능을 보장**하고, 기울기가 지름길로 흘러 학습이 쉬워진다. 결과적으로 더 깊은 ResNet이 더 낮은 오차를 달성했다.

문제 31. Bottleneck의 1×1 conv 역할

해설 — 문제 31

1×1 **convolution의 역할**: 공간 크기는 그대로 두고 **채널 수(차원)를 줄이거나 늘리는** 역할.

- 첫 1×1 : 입력 채널(예: 256)을 줄여(예: 64) 비싼 3×3 연산을 **저차원에서** 수행 $\rightarrow$ 연산량 절감.
- 마지막 1×1 : 채널을 다시 원래 차원(256)으로 복원하여 잔차 덧셈이 가능하도록 맞춤.

이점: 3×3 conv를 고차원에서 직접 돌리는 것보다, 차원을 줄였다가 복원하는 “병목” 구조가 **훨씬 적은 연산량**으로 같은 표현력을 확보한다. 그래서 ResNet-50/101/152 같은 깊은 망에 쓰인다.

문제 32. 미니 CNN dimension 추적

해설 — 문제 32

SAME conv($P = 1, K = 3, S = 1$)는 크기 유지, 풀링($K = 2, S = 2$)은 절반:

(1) Conv(16, SAME): $32 \times 32 \times 3 \rightarrow 32 \times 32 \times 16$

(2) MaxPool(2, 2): $\frac{32-2}{2} + 1 = 16 \Rightarrow 16 \times 16 \times 16$

(3) Conv(32, SAME): $16 \times 16 \times 32$ (크기 유지, 채널 32)

(4) MaxPool(2, 2): $\frac{16-2}{2} + 1 = 8 \Rightarrow 8 \times 8 \times 32$

Flatten 길이: $8 \times 8 \times 32 = 2,048$.